# Modelo de identificação de disfunção tireoidiana

Lucas Amaral Taylor

# Objetivo

**Classificar** pacientes, com base nas variáveis do conjunto de dados, quanto à **presença** ou **ausência** de disfunção tireoidiana.

# Metodologia

# Base original

Disponível em: 10.24432/C5D010

**CC BY 4.0**

- Garvan Institute of Medical Research - Austrália
- Análise realizada em 1986
- Documentação de Ross Quinlan

# Nossos dados

Temos 3772 linhas separadas 30 variáveis à nossa disposição, que levam em consideração:

- **Demográficas**: Idade e sexo
- **Histórico clínico,** como uso de medicação, condições pré-existentes e intervenções médicas
- **Laboratoriais,** como dosagens hormonais da tireoide (TSH, T3, T4)

# Tratamento de dados

Criação da base tratada para futuras explorações

THYROID_DISEASE_TRATADO.csv

## O que tratamos?

- Dados Nulos e Ausentes
- Outliers

Além disso...

- Padronização de dados
- Eliminação de colunas desnecessárias

# Quais são os mais relevantes para o que queremos identificar?

TSH: Thyroid Stimulating Hormone

FTI: Free Thyroxine Index

TT4: Total Thyroxine

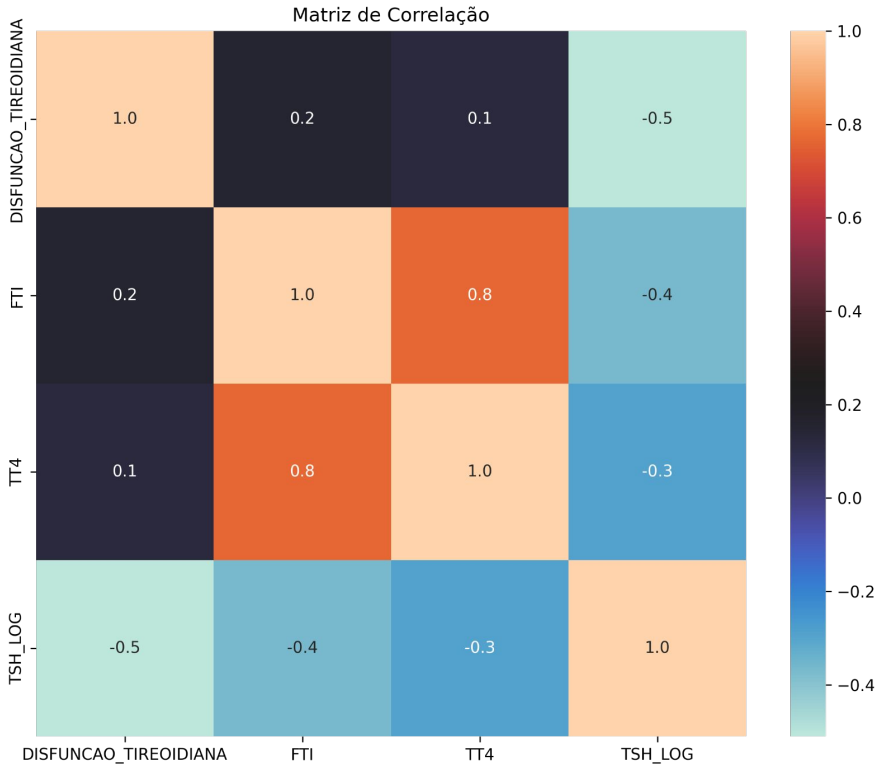


Criamos uma versão reduzida do DataFrame apenas com os dados mais relevantes:
THYROID_DISEASE_TRATADO_REDUZIDO.csv

# TSH

Valores de TSH (em log) **menores que 1.5 é forte** indicativo **forte** de disfunção tireoidiana.

Enquanto, valores maiores indicam ausência.

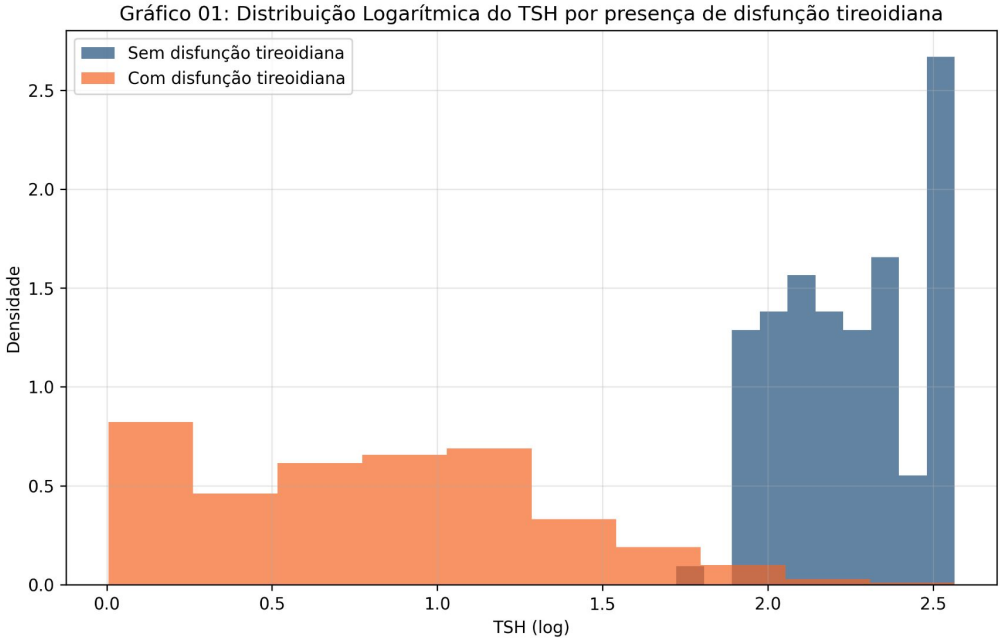

# TT4

**Para valores de TT4 abaixo de de 115,** a tendência é o paciente **não** ter disfunção tireoidiana. Acima deste valor, a tendência é o paciente ter esta condição.

**Para valores de TT4 acima de 150,** temos **apenas** pacientes **com** disfunção tireoidiana.

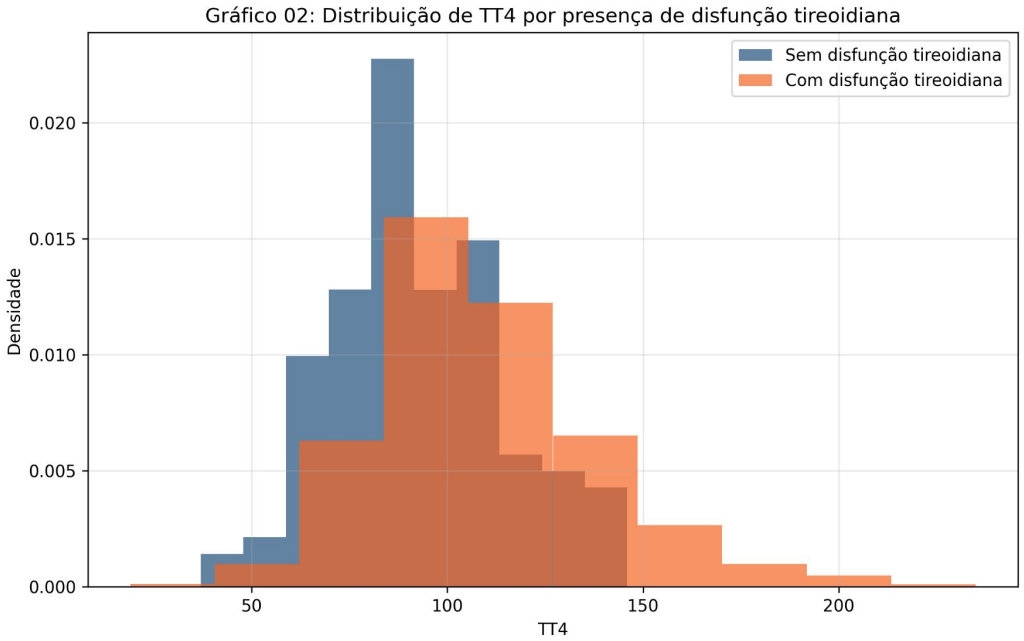

# FTI

Mesma situação que o TT4:

**Abaixo de de 115,** a tendência é o paciente **não** ter disfunção tireoidiana, acima deste valor, sim.

**Para valores de TT4 acima de 155,** temos **apenas** pacientes **com** disfunção tireoidiana.

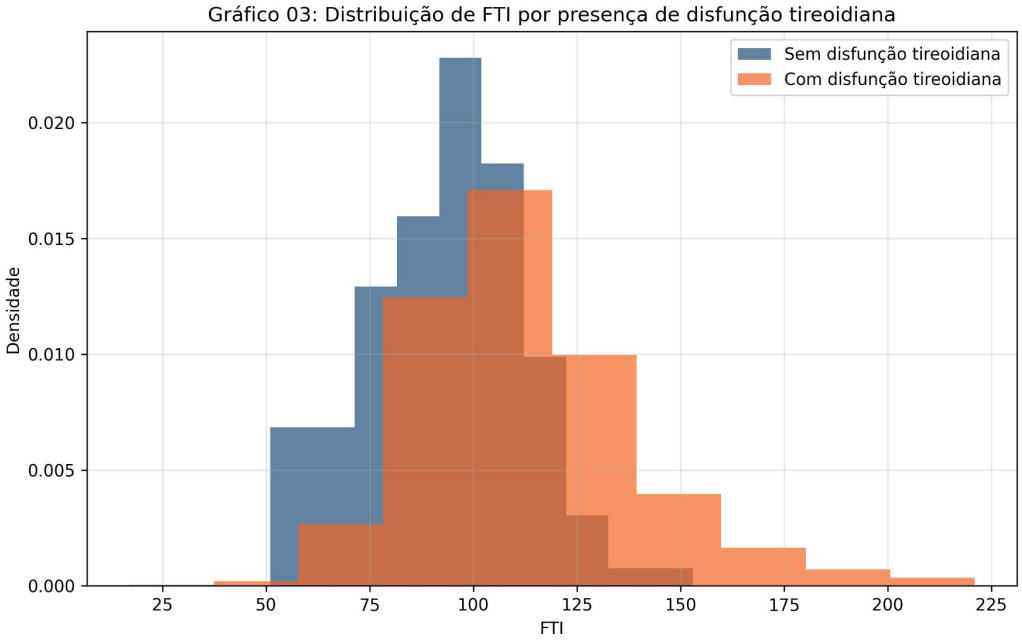

# Atenção!

Os dados estão

**extremamente**

**desbalanceados.**

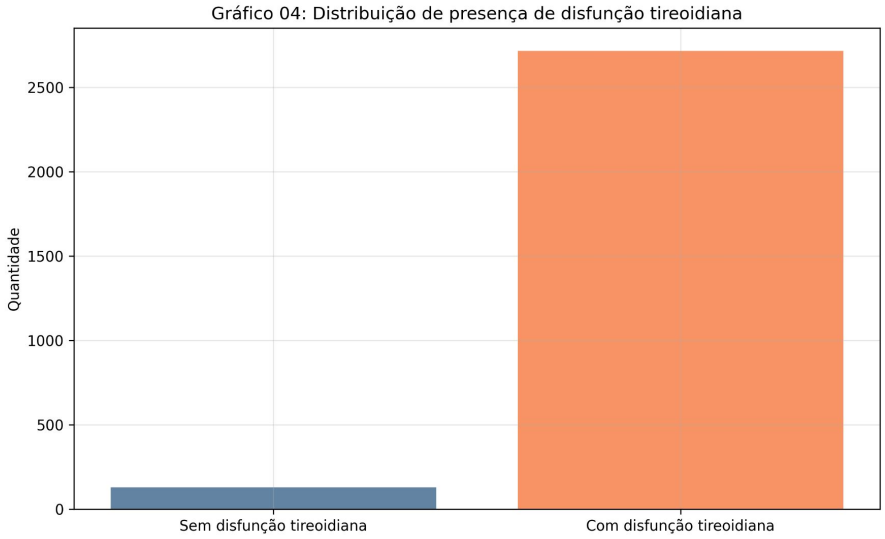

–

Aplicamos balanceamento para o **treinamento** no nosso modelo.

–

Apesar disso, nosso **teste** estará desbalanceado. Assim, focaremos na **métrica f1-score** em nossa análise

# Modelagem

Apresentaremos apenas os resultados da base de teste

1. Explorar modelos
2. Identificar modelos promissores
3. Definir os hiperparâmetros dos modelos promissores
4. Definição do melhor modelo

# Treinamento inicial dos modelos

| MODELOS | PRECISION | RECALL | F1 | ROC_AUC |
|---|---|---|---|---|
| 🥇 NAIVE BAYES | 0,995 | 0,988 | 0,991 | 0,994 |
| 🥈 RANDOM FOREST | 0,994 | 0,989 | 0,991 | 0,994 |
| 🥉 XGBOOST | 0,997 | 0,987 | 0,992 | 0,993 |
| REGRESSÃO LOGÍSTICA | 1 | 0,964 | 0,982 | 0,994 |
| SVM | 1 | 0,972 | 0,986 | 0,994 |

# Desempenho: Random Forest (com Hiperparâmetros Otimizados)

| | CLASSE 0 | CLASSE 1 | ACCURACY | MACRO AVG | WEIGHTED AVG |
|---|---|---|---|---|---|
| PRECISION | 0,667 | 1 | 0,986 | 0,833 | 0,991 |
| RECALL | 1 | 0,986 | 0,986 | 0,993 | 0,986 |
| F1-SCORE | 0,8 | 0,993 | 0,986 | 0,896 | 0,987 |
| SUPPORT | 16 | 554 | 0,986 | 570 | 570 |

# Desempenho: Naive Bayes

| | CLASSE 0 | CLASSE 1 | ACCURACY | MACRO AVG | WEIGHTED AVG |
|---|---|---|---|---|---|
| PRECISION | 0,714 | 0,998 | 0,988 | 0,856 | 0,99 |
| RECALL | 0,938 | 0,989 | 0,988 | 0,963 | 0,988 |
| F1-SCORE | 0,811 | 0,994 | 0,988 | 0,902 | 0,989 |
| SUPPORT | 16 | 554 | 0,988 | 570 | 570 |

# Desempenho: XGBoost (com Hiperparâmetros Otimizados)

| | CLASSE 0 | CLASSE 1 | ACCURACY | MACRO AVG | WEIGHTED AVG |
|---|---|---|---|---|---|
| PRECISION | 0,762 | 1 | 0,991 | 0,881 | 0,993 |
| RECALL | 1 | 0,991 | 0,991 | 0,995 | 0,991 |
| F1-SCORE | 0,865 | 0,995 | 0,991 | 0,93 | 0,992 |
| SUPPORT | 16 | 554 | 0,991 | 570 | 570 |

# Identificação do melhor modelo

| | F1-SCORE | | |
|---|---|---|---|
| MODELO | CLASSE 0 | CLASSE 1 | ACCURACY |
| XGBOOST | 0,865 | 0,995 | 0,991 |
| NAIVE BAYES | 0,811 | 0,994 | 0,988 |
| RANDOM FOREST | 0,8 | 0,993 | 0,986 |

# Resultados finais

1. Features mais importantes
2. Curva ROC
3. Matriz de confusão

# Features mais importantes

| FEATURE | IMPORTANCE |
| --- | --- |
| TSH_LOG | 89,24% |
| FTI | 7,34% |
| TT4 | 3,42% |

# Curva ROC

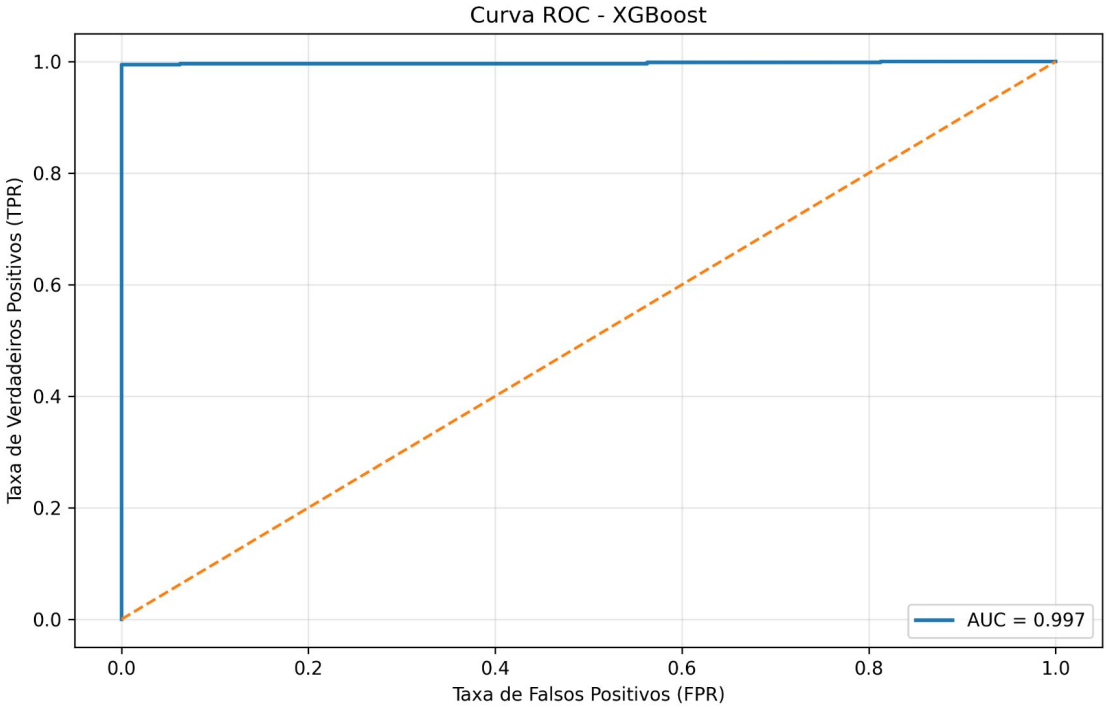
Curva ROC - XGBoost
Taxa de Verdadeiros Positivos (TPR)
Taxa de Falsos Positivos (FPR)
0.0
0.2
0.4
0.6
0.8
1.0
AUC = 0.997

# Matriz de confusão

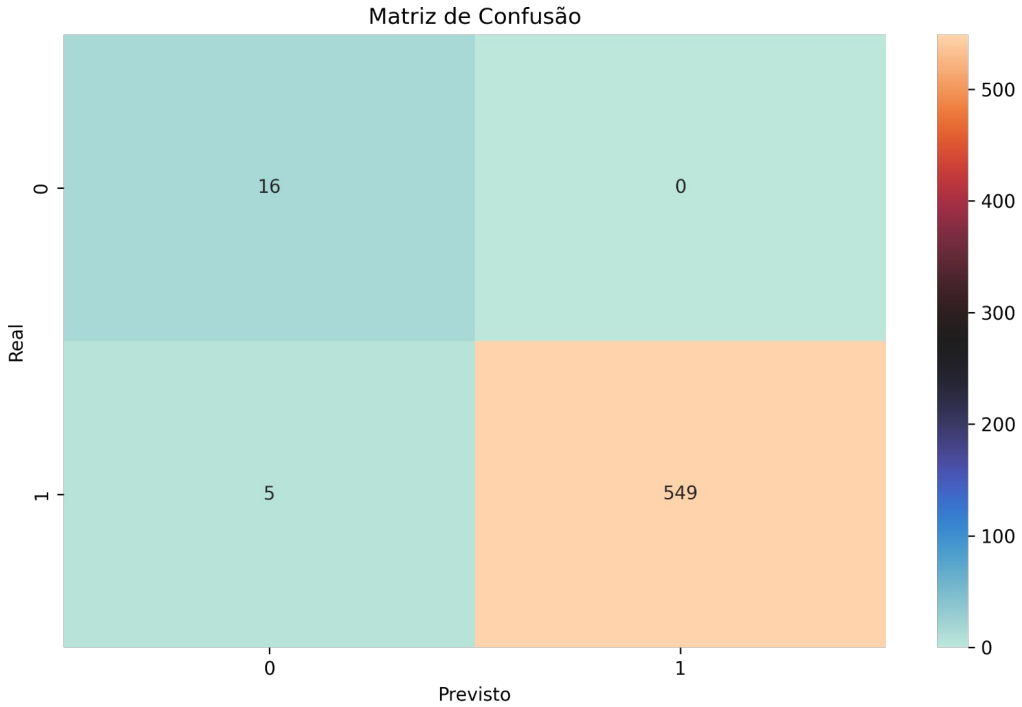

—

Neste problema, priorizamos a **classe 1**, pois é mais crítico não detectar a doença quando ela está presente (*falso negativo*) do que indicá-la quando está ausente (*falso positivo*).

—

O modelo **XGBoost otimizado** verificou-se ser a melhor opção para a abordagem deste problema

No geral, obtivemos **excelentes** resultados para a identificação da presença de disfunção tireoidiana.